



Vamos antecipar o futuro?

AVALIAÇÃO PRÁTICA ENGENHEIRO DE DADOS

10 DE JULHO DE 2026

1. CONTEXTO DO DESAFIO

A empresa fictícia Urban Mobility Analytics deseja construir um pequeno pipeline de dados para analisar corridas de táxi a partir de uma base pública.

O candidato deverá baixar dados públicos de corridas de táxi, tratar inconsistências, carregar os dados em PostgreSQL, criar uma modelagem analítica simples com dbt e orquestrar o fluxo com Airflow na arquitetura medalhão.

A solução deve utilizar Python, PySpark, PostgreSQL, dbt, Airflow. O candidato deve explicar porque utilizou cada ferramenta nas fases do projeto.

A arquitetura usada será a medalhão onde na camada bronze serão armazenados os arquivos .parquet, na camada silver os dados consolidados e tratados da camada bronze e na camada ouro os dados disponibilizados para as análises.

Os códigos devem ser compartilhados via Github para [telveny.nascimento](https://github.com/telveny.nascimento).

2. OBJETIVO

Construir um pipeline de dados simples, funcional e que possa ser executado semanalmente, contendo:

- Ingestão dos arquivos;
- Tratamento com Python ou PySpark;
- Carga em PostgreSQL;
- Modelagem analítica com dbt;
- Orquestração com Airflow;
- Testes de qualidade;
- Documentação básica de execução.

3. DADOS PARA O DESAFIO

A base sugerida é o NYC TLC Trip Record Data, no **mínimo** 6 mês de dados de Yellow Taxi que deve ser baixada pelo link <https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>

Corridas de táxi do ano de 2025

arquivo: yellow_tripdata_YYYY-MM.parquet

Obs.: a atualização dos arquivos deve ser incremental.

nyc.gov/site/tlc/about/tlc-trip-record-data.page

min  softwares  AWS  imagens  pdf  Diabetes  Fonte de Dados  IA  Python  Comparativos  estudos  Figma  icones 

▼ 2025

Janeiro

- Registros de viagens de táxi amarelo (PARQUET)
- Registros de viagens de táxi verde (PARQUET)
- Registros de viagens de veículos de aluguel (PARQUET)
- Registros de viagens de veículos de aluguel de alto volume (PARQUET)

Julho


- Registros de viagens de táxi amarelo (PARQUET)
- Registros de viagens de táxi verde (PARQUET)
- Registros de viagens de veículos de aluguel (PARQUET)
- Registros de viagens de veículos de aluguel de alto volume (PARQUET)

3. DADOS PARA O DESAFIO

A base sugerida é o NYC TLC Trip Record Data, no **mínimo** 6 mês de dados de Yellow Taxi que deve ser baixada pelo link <https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>

Corridas de táxi do ano de 2025

arquivo: yellow_tripdata_YYYY-MM.parque



4. DESAFIO PRÁTICA

- 1) Crie a estrutura do projeto pensando em todas as etapas da arquitetura medalhão.
- 2) Crie a estrutura do banco de dados em PostgreSQL separado pelas camadas da arquitetura.
- 3) Crie um módulo Python responsável por baixar automaticamente os arquivos Parquet da TLC para um mês do período escolhido do base de Corridas de táxi e gravar os dados na camada bruta do arquitetura.
- 4) Crie manualmente a tabela de referência de tipos de pagamento com base no dicionário de dados da TLC, contendo os campos: `payment_type` (inteiro), `payment_description` (texto) e `is_valid_payment` (boolean). Insira os dados conforme a tabela:

payment_type	payment_description	is_valid_payment
1	Credit card	true
2	Cash	true
3	No charge	false
4	Dispute	false
5	Unknown	false
6	Voided trip	false

4. DESAFIO PRÁTICA

5) Crie um job PySpark para ler os arquivos da camada bronze para gerar a camada silver do data lake.

Regras de negócio para gerar a camada Silver.

- Criar de 3 a 6 regras de qualidade.
- Sinalizar viagens com duração acima de 6 horas como possível anomalia.
- Sinalizar viagens com distância acima de 100 milhas como possível anomalia.
- Criar competência mensal com base na data de embarque.
- Considerar como receita válida apenas pagamentos válidos.
- criar as colunas: pickup_date, pickup_year_month, trip_duration_minutes, is_valid_trip, invalid_reason.

6) Crie um projeto dbt ou ferramenta similar para transformar os dados carregados no PostgreSQL da camada silver para a camada gold criando as tabelas fatos e dimensões necessárias de acordo com as tabelas utilizadas.

4. DESAFIO PRÁTICA

7) Crie uma materialized view na camada gold para exibir os indicadores por mês, vendorid, mês (yyyymm) e valor:

Indicadores:

- total de corridas por mês;
- Valor total das corridas válidas;
- Ticket médio por corrida;
- Distância média;

8) Crie uma dag no Ariflow para :

- Baixar arquivos.
- Processar camada silver;
- Processar camada gold;